


Ética de la IA Generativa y Manipulación

Una agenda de investigación orientada al diseño técnico

ASSEMBLY VIEW
SCALE 1:35



ASSEMBLY VIEW
SCALE 1:50

Presentado por:
Stiven Aguirre Granada
Jorge Andres Mora Leon
Juan Manuel Barrero Mendoza

La doble cara de la influencia automatizada

La Promesa



Intervenciones efectivas en salud pública a escala poblacional.



Comunicación gubernamental clara frente a la desinformación.



Impactos sociales positivos basados en persuasión racional.

El Peligro



Campañas de suplantación y estafas hiper-personalizadas.



Explotación automatizada de sesgos cognitivos.




Manipulación encubierta impulsada por modelos de mercado.

Problema Estructural: La IA generativa escala el riesgo moral al recompensar la persuasión efectiva, independientemente de su legitimidad ética.

El eslabón perdido en la regulación de la IA

Marcos Regulatorios (Ej. AI Act)
Objetivo: Prohibir la manipulación para proteger la autonomía y la democracia.




Falla Crítica: Concepto Operativo Faltante

Desarrollo Técnico
Objetivo: Construir sistemas alineados que sean útiles, inofensivos y honestos.

Carecemos de una conceptualización técnica de qué es exactamente la manipulación, lo que impide traducirla en código y requisitos de diseño computacional.

Diseño Sensible a los Valores (VSD)

Metodología iterativa para programar la no-manipulación



Evaluando el modelo del Espectro de Influencia



Conclusión: Un requerimiento de diseño en IA exige límites paramétricos más precisos que una escala analógica.

Diagnóstico de fallos en los criterios clásicos

Criterio Filosófico	Definición Conceptual	Exceso (Falso Positivo)	Fallo o Carencia (Falso Negativo)
Influencia Oculta	El usuario no es consciente del mecanismo.	Penaliza heurísticas subconscientes benignas.	Ignora patrones oscuros obvios ("Roach motels").
Bypass de Racionalidad	Eludir el análisis lógico consciente.	Penaliza confiar racionalmente en testimonios de expertos.	Ignora la presión social, que suele ser totalmente consciente.
Truco Intencional	Voluntad manifiesta de engañar al usuario.	No aplica a sistemas matemáticos sin consciencia.	Incapaz de detectar manipulación emergente autónoma.

Veredicto: Los modelos filosóficos clásicos basados en ocultamiento o intencionalidad colapsan al auditar sistemas estocásticos automatizados.

Intención humana frente a emergencia algorítmica

IA como Herramienta




- ✓ Existe una intención humana clara y programada.
- ✓ Un estafador utiliza la IA generativa para crear mensajes de phishing a escala.



- ✓ El engaño es deliberado.

IA como Manipulador Autónomo



⚠ Emergencia sin intencionalidad.


⚠ Un algoritmo optimiza ciegamente la retención de usuarios. A través de ensayo y error masivo, aprende tácticas tóxicas para alterar el comportamiento.

⚠ Nadie programó la intención de manipular, el sistema simplemente optimiza un parámetro numérico.


El paradigma cambia:

La evaluación ética en IA no puede depender de auditar intenciones humanas, debe enfocarse en auditar los resultados paramétricos.

La Solución Conceptual: El Criterio de Indiferencia



Fase Empírica: La maleabilidad de la percepción humana



El Concepto Popular ('Folk')

Los datos empíricos demuestran que las personas juzgan la manipulación de manera subjetiva; la gravedad percibida cambia drásticamente según el usuario y el contexto.

El Riesgo Operativo

La 'normalización' algorítmica. Si una IA altera gradualmente nuestro entorno digital, terminaremos aceptando una influencia encubierta como si fuera una persuasión totalmente normal.

La Regla de Oro en VSD


La ética tecnológica debe anclar el diseño base. No podemos delegar las restricciones de seguridad exclusivamente a lo que el público considera aceptable en un momento determinado.

Fase de Diseño: Los puntos ciegos del RLHF




Degradación Temporal: Sistemas con aprendizaje continuo han demostrado descarrilarse éticamente tras su despliegue activo. Se requiere un monitoreo basado en auditorías paramétricas, no solo retroalimentación subjetiva.

El futuro inmediato: Persuasión hiper-personalizada



0.5pt

Automatización Total
del Perfilado



Dependencia Humana en el Bucle

Se requiere un actor malicioso para dirigir manualmente campañas de desinformación usando la IA como un simple redactor de textos.

Persuasión Autónoma Adaptativa

La IA genera perfiles psicológicos masivos en tiempo real y calibra autónomamente sus resultados para maximizar la eficacia de la persuasión empírica, sin supervisión humana.

El Mandato Técnico: Implementar el 'Criterio de Indiferencia' hoy es la única infraestructura viable para auditar los modelos algorítmicos antes de que se vuelvan cajas negras de manipulación autónoma.

La arquitectura definitiva para una IA responsable

1. El Diagnóstico


La IA Generativa escala el riesgo moral exponencialmente. La dependencia de la regulación legal es insuficiente; necesitamos anclas matemáticas y restricciones a nivel de diseño base.

2. El Marco Conceptual

Las definiciones anticuadas basadas en la 'intención' de engañar han colapsado. Adoptar la auditoría bajo el Criterio de Indiferencia hacia la verdad es el único estándar riguroso.

3. El Mandato de Diseño

Debemos superar la dependencia ciega en la retroalimentación humana empírica (RLHF), construyendo sistemas de monitoreo técnico iterativo continuo a largo plazo.



Construir tecnología confiable y democrática no es un debate semántico; exige ética codificada directamente en los cimientos arquitectónicos del sistema.